Kacper Grzelak, Piotr Michalski

Raport

Celem projektu było porównanie czasu przykładowych zapytań do bazy relacyjnej i obiektowej, oraz sprawdzenie ich skalowalności względem liczby rekordów.
Do testów użyliśmy bazy danych z filmami w liczbie 27 278, oraz ocenami w liczbie 20 000 263. Dane pobraliśmy ze strony https://grouplens.org/datasets/movielens/ (MovieLens 20m Dataset). Aby testować skalowalność przeprowadzaliśmy zapytania dla 5, 10, 15, 20 milionów ocen.

MySQL

W testach bazy relacyjnej łączyliśmy się z MySQL poprzez SQLAlchemy. Zapytania formułowane były poprzez SQL. Model bazy został skonstruowany w następujący sposób:

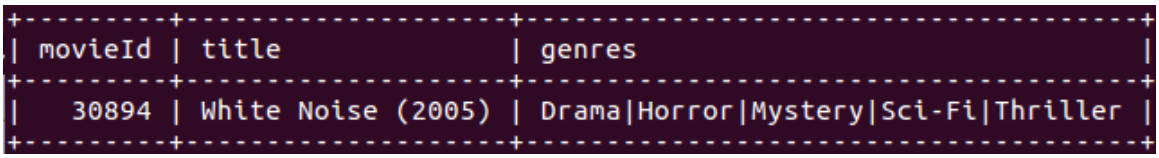

movieId	title	genres
30894	White Noise (2005)	Drama|Horror|Mystery|Sci-Fi|Thriller

Przykładowy rekord z tabeli „movies”

W pierwszej tabeli(„movies”) rekord posiada 3 kolumny:

- movieId – klucz główny tabeli, identyfikator filmu
- title – tytuł filmu
- genres – gatunki filmu

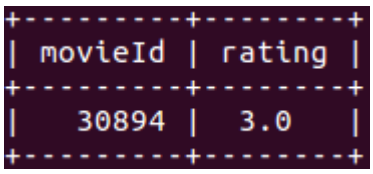

movieId	rating
30894	3.0

Przykładowy rekord z tabeli „ratings”

W drugiej tabeli(„ratings”) rekord posiada 2 kolumny:

- movieId – klucz obcy odpowiadający filmowi z pierwszej tabeli
- rating – ocena filmu

Tabele zostały połączone relacją jeden do wielu.

ZODB

W testach bazy obiektowej łączyliśmy się z ZODB poprzez ZEO. Rekordy w bazie danych przechowywaliśmy w B-drzewie jako obiekty klasy Movie.

```
class Movie(persistent.Persistent):
        def __init__(self,title, genres):
                self.title = title
                self.genres = genres.split("|")
                self.ratings = []

        def set_title(self, title):
                self.title = title

        def set_genres(self, genres):
                self.genres = genres

        def set_ratings(self, ratings):
                self.ratings = ratings

        def addRating(self,r):
                self.ratings.append(r)
```

Klasa Movie

Oceny filmów przechowywane są w tym samym obiekcie w polu ratings (lista).

TESTY

Dla każdej z baz przeprowadziliśmy po 3 testy z pomiarami czasu:

- Test nr 1 – zapytanie o najlepszy film z gatunku Thriller posiadający co najmniej 20 ocen
- Test nr 2 – 250000 zapytań o losowy film
- Test nr 3 – dopisanie 10000 rekordów do bazy danych.

Funkcje testujące znajdują się w załączniku pod nazwami:

- Baza relacyjna (mysql.py)
  - Test nr 1 – bestThriller()
  - Test nr 2 – random1Mmovies(m, movieList = [])
    - Powyższa funkcja wykonuje 3 różne zapytania w zależności od parametru „m”. W teście użyliśmy najbardziej optymalnego zapytania(m = 1) polegającego na założeniu, że serwer posiada listę id filmów i na jej podstawie odpytuje bazę danych
  - Test nr 3 – saveRandomData()
- Baza obiektowa (testyobiektowe.py)
  - Test nr 1 – bestThriller(tree) wraz z funkcją pomocniczą ave(rList)
  - Test nr 2 – randomMovies(tree)
  - Test nr 3 – saveRandomData(tree)

WYNIKI

Test nr 1

	Baza relacyjna	Baza obiektowa
Ilość ocen	Czas wykonania [s]	
5 mln	11.7366361618042	14.94456171989441
10 mln	23.00187373161316	18.013745307922363
15 mln	35.28084588050842	21.451774835586548
20 mln	46.77485370635986	24.14399027824402

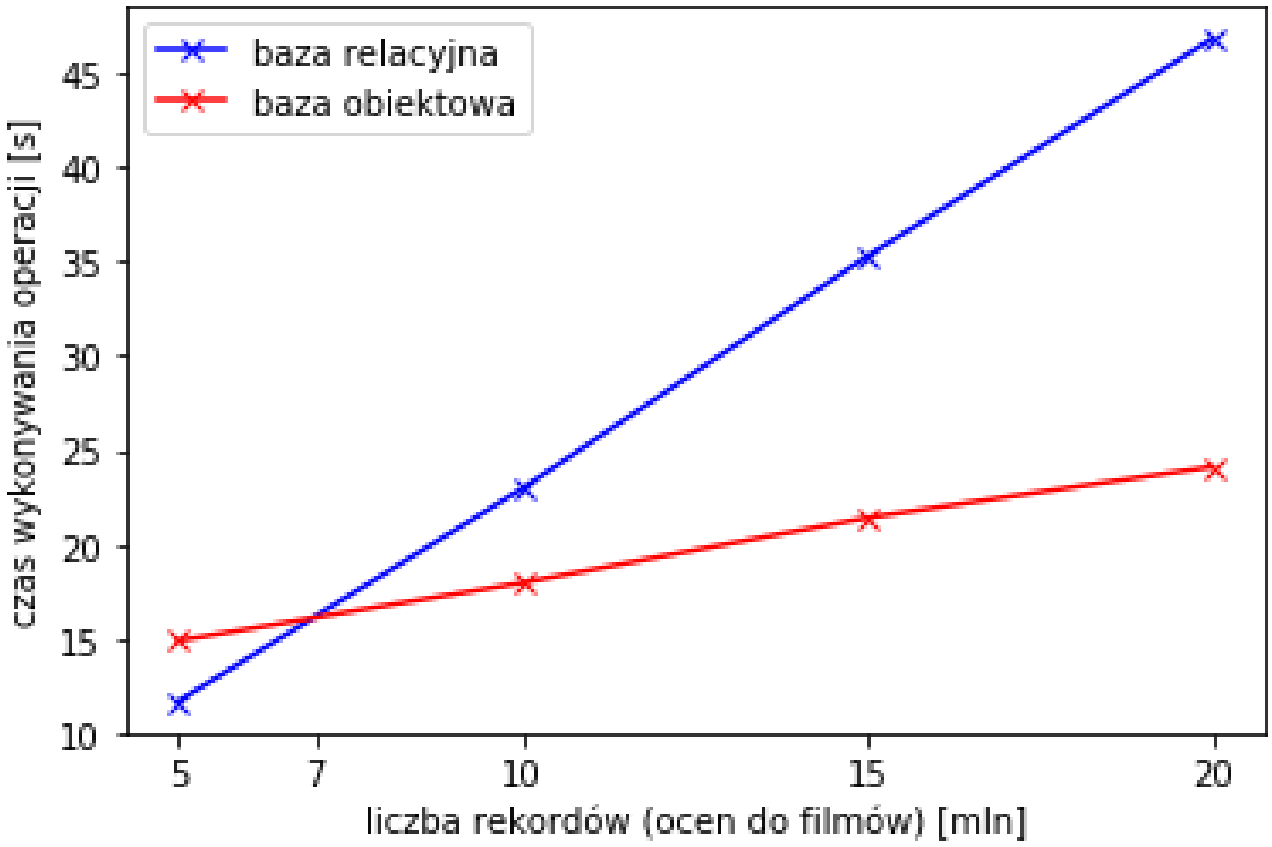

Test nr 2

	Baza relacyjna	Baza obiektowa
Ilość ocen	Czas wykonania [s]	
5 mln	74.95877528190613	9.511908292770386
10 mln	74.25568914413452	9.352771282196045
15 mln	75.54806280136108	9.350659608840942
20 mln	74.40225386619568	9.325289011001587

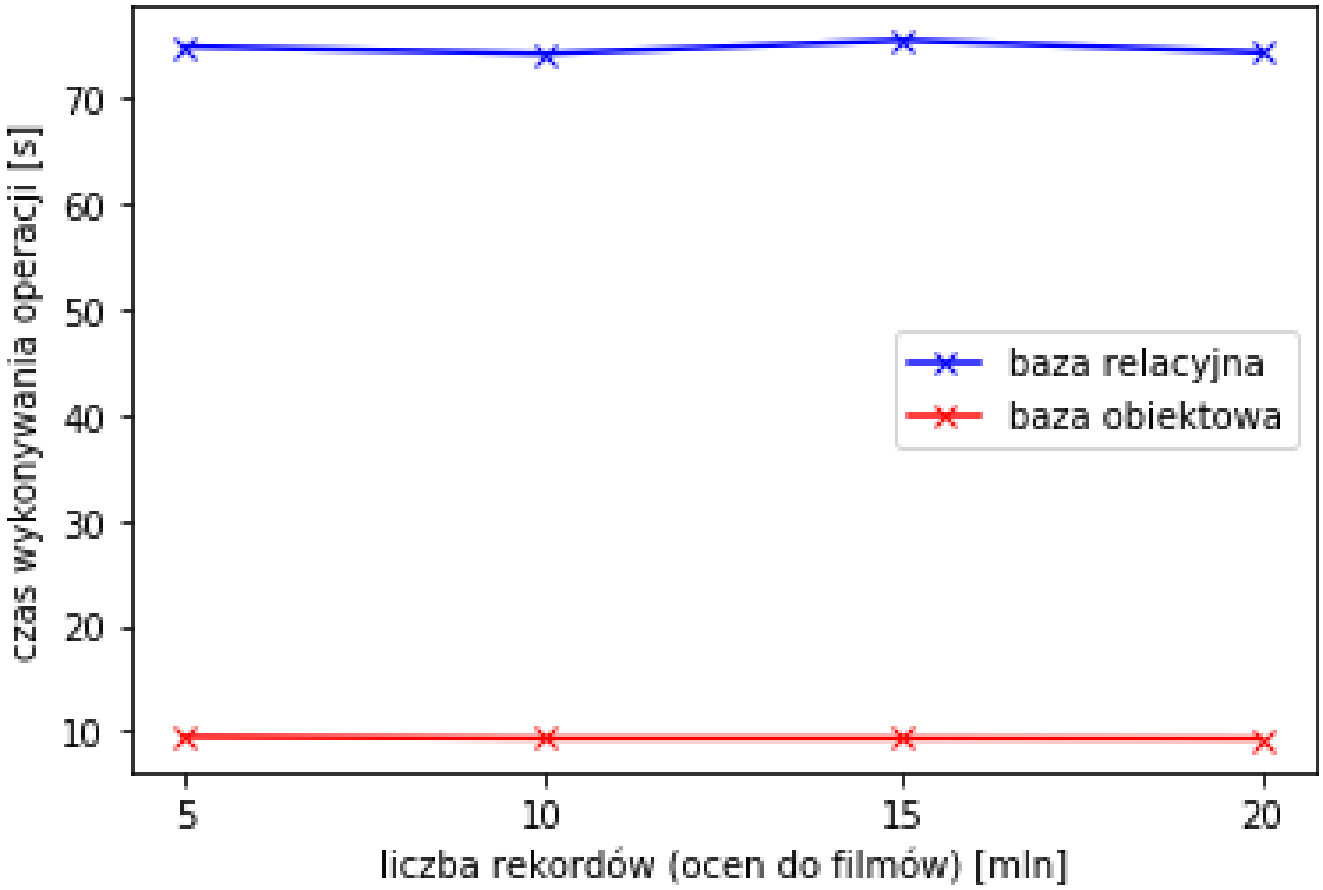

Test nr 3

	Baza relacyjna	Baza obiektowa
Ilość ocen	Czas wykonania [s]	
5 mln	96.9652726650238	88.76216793060303
10 mln	97.65681028366089	88.26180005073547
15 mln	97.42846298217773	88.41565036773682
20 mln	95.64041709899902	88.67719268798828

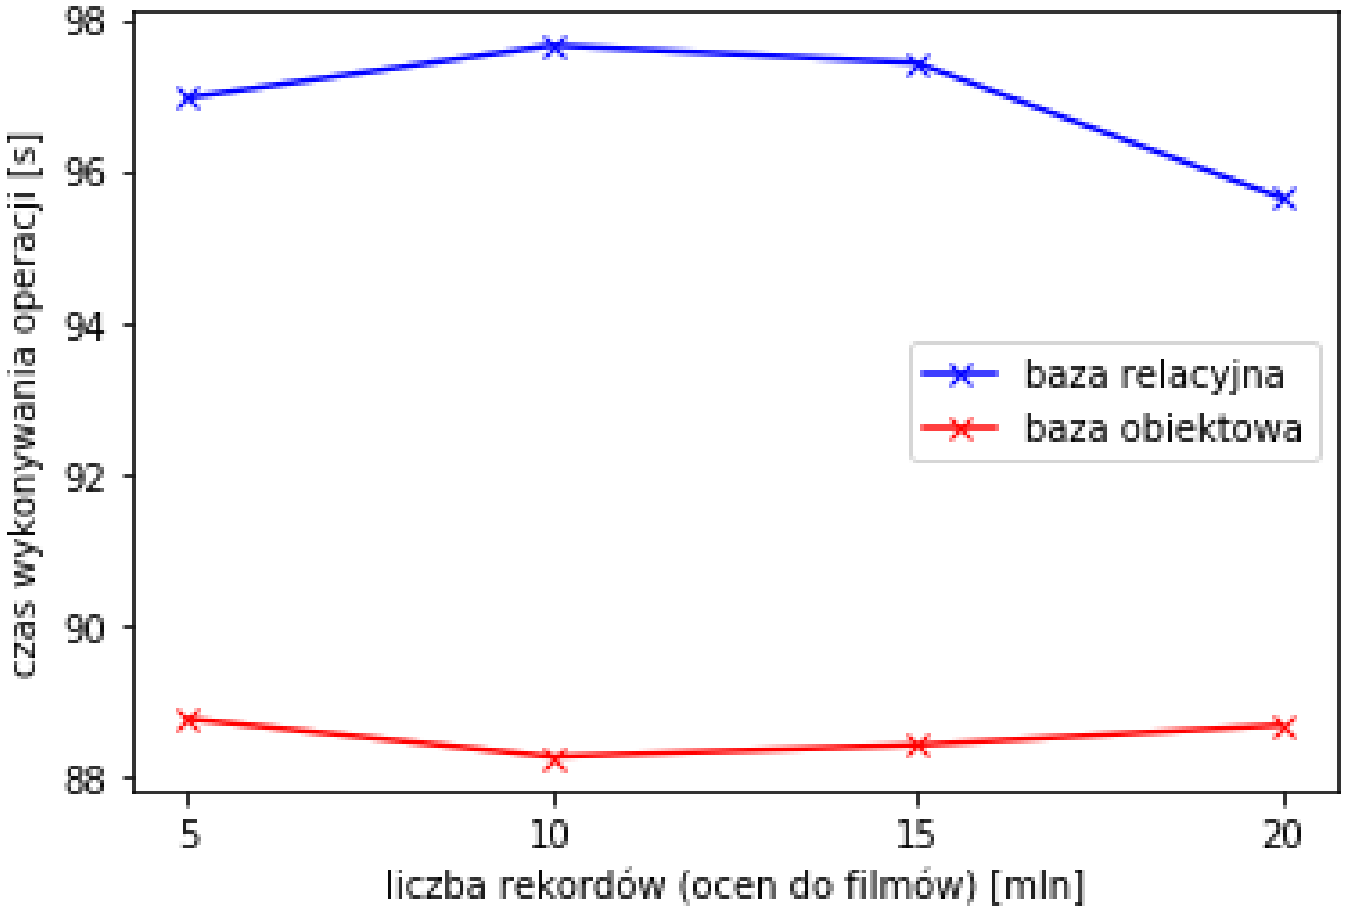

WNIOSKI

W naszych testach obiektowa baza danych wypadła lepiej względem wydajności. W pierwszym teście możemy zauważyć, że obiektowa baza danych skaluje się lepiej niż baza relacyjna i już dla około 7 milionów ocen była bardziej wydajna. Spowodowane jest to korzystniejszym modelem danych polegającym na przechowywaniu listy ocen w tym samym obiekcie co pozostałe dane filmu. W pozostałych testach nie ma zmian w wydajności względem liczby ocen. Zapytanie o losowy film jest znacznie bardziej wydajne w obiektowej bazie danych. Średni czas zapytania o 1 film wyniósł 0.000299s w MySQL i 0.000038s w ZODB. W przybliżeniu jest to około 8 razy szybciej. W trzecim teście polegającym na zapisie filmów wraz z jego ocenami obie bazy osiągnęły podobne wyniki. Średni czas zapisu jednego filmu z ocenami wyniósł 0.009692 w MySQL i 0.008852s w ZODB.

DODATKOWE TESTY

Zrobiliśmy również dodatkowe testy na 20mln bazach.
Sprawdziliśmy szybkość wyszukiwania najlepszego Thrillera w obiektowej bazie danych w zmienionym modelu używając dodatkowej struktury B-drzewa zawierającego wszystkie Thrillery z co najmniej dwudziestoma ocenami. Czas wyszukania najlepszego Thrillera wyniósł wtedy 5.025348663330078s. Zapytanie z oryginalnego modelu wyniosło dla porównania 24.14399027824402s.

Sprawdziliśmy dla drugiego testu wylosowanie 250000 filmów w relacyjnej bazie danych poprzez (bardzo wolne) zapytanie SQL - 'SELECT title FROM movies ORDER BY Rand() LIMIT 1;'
Przy takim zapytaniu otrzymaliśmy czas równy 2571.9706058502197s (~43 min). Czas wylosowania jednego filmu wyniósł około 0.010287s.

Załączniki:
- plik importu csv do MySQL (importSQL)
- plik importu csv do ZODB (obiektowa.py)
- plik testów do MySQL (mysql.py)
- plik testów do ZODB (testyobiektowe.py)